

极小化方法

一、与线性方程组等价的变分问题

二、最速下降法

三、共轭梯度法(共轭斜量法)

四、预条件共轭梯度法



一、与线性方程组等价的变分问题

设 $x, y \in R^n$, 记 $(x, y) = x^T y$

- $(x, y) = (y, x)$;
- $(tx, y) = t(x, y)$;
- $(x+y, z) = (x, z) + (y, z)$;
- $(x, x) \geq 0$, 且 $(x, x) = 0 \Leftrightarrow x = 0$;

设 A 是 n 阶对称正定阵

- $(Ax, y) = (x, Ay)$;
- $(Ax, x) \geq 0$, 且 $(Ax, x) = 0 \Leftrightarrow x = 0$



设 A 对称正定，求解的线性方程组为

$$Ax = b \quad (1)$$

其中 $A = (a_{ij}) \in R^{n \times n}$, $x = (x_1, x_2, \dots, x_n)^T$, $b = (b_1, b_2, \dots, b_n)^T$

对应的二次函数 $\varphi: R^{n \times n} \rightarrow R$ ，称为模函数，定义为

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i \quad (2)$$

例 : ◆ $A = \begin{bmatrix} 1 & 2 \\ 2 & 6 \end{bmatrix}, \quad b = \begin{bmatrix} 4 \\ 1 \end{bmatrix}$


$$\varphi(x) = \frac{1}{2}(x_1^2 + 6x_2^2 + 4x_1x_2) - (4x_1 + 1x_2)$$



模函数(二维)


正定

$$\underline{\mathbf{x}^T \mathbf{A} \mathbf{x} > 0}$$




负定

$$\underline{\mathbf{x}^T \mathbf{A} \mathbf{x} < 0}$$




正不定

$$\underline{\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0}$$




不定



正定的情形

(a)



$$\varphi(x) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i$$

φ 有如下性质：

(1) 对一切 $x \in R^n$ ，有 $\nabla \varphi(x) = \text{grad } \varphi(x) = Ax - b = -r$ (3)

证：
$$\frac{\partial \varphi}{\partial x_i} = \sum_{j=1}^n a_{ij} x_j - b_i = -r_i, \quad i = 1, 2, \dots, n$$

$$\text{grad } \varphi(x) = \left[\frac{\partial \varphi}{\partial x_1} \quad \dots \quad \frac{\partial \varphi}{\partial x_n} \right]^T = Ax - b = -r$$



(2) 对一切 $x, y \in R^n, \alpha \in R$

$$\begin{aligned}\varphi(x + \alpha y) &= \frac{1}{2}(A(x + \alpha y), x + \alpha y) - (b, x + \alpha y) \\&= \frac{1}{2}(Ax, x) - (b, x) + \alpha(Ax, y) - \alpha(b, y) + \frac{\alpha^2}{2}(Ay, y) \\&= \varphi(x) + \alpha(Ax - b, y) + \frac{\alpha^2}{2}(Ay, y)\end{aligned}\quad (4)$$

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x)$$



定理1 设 $A = (a_{ij})_{n \times n}$ 为**实对称正定矩阵**, $b, x \in R^n$, 则 x 使二次函数

$$f(x) = \frac{1}{2}(Ax, x) - (b, x)$$

取极小值 $\Leftrightarrow x$ 是线性方程组 $Ax = b$ 的解。

证明: **必要性(解是极小值点)**. 设 u 是 $Ax = b$ 的解
 $\rightarrow Au = b \rightarrow f(u) = -\frac{1}{2}(Au, u)$

对任意 $x \in R^n$, 只须证明 $f(x) - f(u) \geq 0$

$$\begin{aligned} f(x) - f(u) &= \frac{1}{2}(Ax, x) - (b, x) + \frac{1}{2}(Au, u) \\ &= \frac{1}{2}(A(x - u), (x - u)) \geq 0 \end{aligned}$$



充分性. 设 u 使 $f(x)$ 取极小值. 取非零向量 $x \in R^n$,
对任意 $t \in R$, 有

$$\begin{aligned} f(u + tx) &= \frac{1}{2}(A(u + tx), u + tx) - (b, u + tx) \\ &= f(u) + t(Au - b, x) + \frac{t^2}{2}(Ax, x) \end{aligned}$$

令 $g(t) = f(u + tx)$, 由于 $g(t)$ 是关于 t 的连续函数, 当 $g'(t) = 0$, 取得极小值。

另一方面令 $g(t) = f(u + tx)$, 当 $t=0$ 时, $g(0) = f(u)$ 达到极小值。

于是 $g'(0) = 0$, 即

$$(Au - b, x) = 0 \quad \rightarrow \quad Au - b = 0$$

所以, u 是方程组 $Ax=b$ 的解.



求二次函数 $\varphi(x)$ 极小值点的一般方法是：

构造一个向量序列 $\{x^{(k)}\}$ ，使 $\varphi(x^{(k)}) \rightarrow \min \varphi(x)$

可以采取以下方法：

(1) 任取一个初始向量 $x^{(0)}$ ，

(2) 构造迭代格式

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}, \quad (k = 0, 1, \dots)$$

其中 $p^{(k)}$ 是搜索方向， α_k 是搜索步长，

(3) 选择 $p^{(k)}$ 和 α_k 使得

$$\varphi(x^{(k+1)}) = \varphi(x^{(k)} + \alpha_k p^{(k)}) < \varphi(x^{(k)})$$

则当 $k \rightarrow \infty$ 时，有 $\varphi(x^{(k)}) \rightarrow \varphi(x^*) = \min_{x \in R^n} \varphi(x)$

(4) 算出误差限 ε ，直到

$$\|x^{(k)} - x^{(k-1)}\| < \varepsilon \text{ 或 } \|r^{(k)}\| = \|b - Ax^{(k)}\| < \varepsilon$$

迭代为止。



对迭代格式

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}, \quad (k = 0, 1, \dots)$$

关键是要确定搜索方向 $\mathbf{p}^{(k)}$ 和搜索步长 α_k 。

(1) 确定搜索方向 $\mathbf{p}^{(k)}$

最速下降法： $\mathbf{p}^{(k)}$ 取为模函数 $\varphi(\mathbf{x})$ 减少最快的方向，
即： $\varphi(\mathbf{x})$ 的负梯度方向 $-\text{grad}(\varphi(\mathbf{x}))$ 。

共轭斜量法：取 A - 共轭方向 $\mathbf{p}^{(k)}$ 。

(2) 确定搜索步长 α_k

确定 α_k 使得从 k 步到 k+1 步是最优的，即：

$$\varphi(\mathbf{x}^{(k+1)}) = \varphi(\mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}) = \min_{\alpha} \varphi(\mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)})$$

这称为沿 $\mathbf{p}^{(k)}$ 方向的一维极小搜索。 $\varphi(\mathbf{x}^{(k+1)})$ 是局部极小。



对确定的搜索方向 $p^{(k)}$, 构造一个 α 的函数

$$\begin{aligned} F(\alpha) &= \varphi(x^{(k+1)}) = \varphi(x^{(k)} + \alpha p^{(k)}) \\ &= \frac{1}{2}(A(x^{(k)} + \alpha p^{(k)}), x^{(k)} + \alpha p^{(k)}) - (b, x^{(k)} + \alpha p^{(k)}) \\ &= \frac{1}{2}(Ax^{(k)}, x^{(k)}) - (b, x^{(k)}) + \alpha(Ax^{(k)}, p^{(k)}) - \alpha(b, p^{(k)}) \\ &\quad + \frac{\alpha^2}{2}(Ap^{(k)}, p^{(k)}) \\ &= \varphi(x^{(k)}) + \alpha(Ax^{(k)} - b, p^{(k)}) + \frac{\alpha^2}{2}(Ap^{(k)}, p^{(k)}) \\ &= \varphi(x^{(k)}) - \alpha(r^{(k)}, p^{(k)}) + \frac{\alpha^2}{2}(Ap^{(k)}, p^{(k)}) \end{aligned}$$

令 $F'(\alpha) = 0$, 即: $-(r^{(k)}, p^{(k)}) + \alpha(Ap^{(k)}, p^{(k)}) = 0$



得
$$\alpha = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$F'(\alpha) = -(r^{(k)}, p^{(k)}) + \alpha(Ap^{(k)}, p^{(k)})$$

$$\because F''(\alpha) = (Ap^{(k)}, p^{(k)}) > 0, \quad (A \text{ 正定})$$

取 $\alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$, α_k 是 $\varphi(x^{(k)} + \alpha p^{(k)})$ 下降的极小值点,

即 α_k 是 $k \rightarrow k+1$ 步的最优步长。



二、最速下降法

最速下降法： $p^{(k)}$ 取为模函数 $\varphi(x)$ 减少最快的方向，
即： $\varphi(x)$ 的负梯度方向 $-\text{grad}(\varphi(x))$ ，
$$p^{(k)} = -\text{grad}(\varphi(x^{(k)})) = r^{(k)}.$$

从 $x^{(0)}$ 出发寻找 $\varphi(x)$ 的极小点， $\varphi(x) = \varphi(x^{(0)})$ 是 $\varphi(x)$ 的等值面，因为 A 正定，它是 n 维空间的一个椭球面，从 $x^{(0)}$ 出发先找一个使 $\varphi(x)$ 减小最快的方向，这就是正交于椭球面的 $\varphi(x)$ 负梯度方向 $-\nabla \varphi(x^{(0)})$ 。



最速下降算法：

(1) 选取 $x^{(0)} \in R^n$

(2) 对 $k = 0, 1, 2, \dots$

$$r^{(k)} = b - Ax^{(k)}$$

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ar^{(k)}, r^{(k)})}$$


$$x^{(k+1)} = x^{(k)} + \alpha_k r^{(k)}$$

(3) 当 $\|x^{(k+1)} - x^{(k)}\| < \varepsilon$ 时，终止迭代。

$$\alpha = -\frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$



目标函数为二次函数， 其等值面为椭球面。



注 最速下降方向反映了目标函数的一种局部性质。它只是局部目标函数值下降最快的方向。

最速下降法是线性收敛的算法。

不难验证，相邻两次的搜索方向是正交的，即

$$(r^{(k+1)}, r^{(k)}) = 0$$



容易看到, $\{\varphi(x^{(k)})\}$ 是单调下降有界序列, 它存在极限,

可以证明 $\lim_{k \rightarrow \infty} x^{(k)} = x^* = A^{-1}b$

而且 $\|x^{(k)} - x^*\|_A \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^k \|x^{(0)} - x^*\|_A$

其中 λ_1, λ_n 分别是对称正定阵 A 的最大、最小特征值,

$$\|u\|_A = (Au, u)^{1/2}$$

当 $\lambda_1 \gg \lambda_n$ 时, 收敛是很慢的,


当 $\|r^{(k)}\|$ 很小时, 因舍入误差的影响, 计算将出现

不稳定现象。



三、共轭梯度法 (CG) (共轭斜量法)

$$\nabla f(x) = AX - b$$



$$x^* = x^{(1)} + tp^{(1)}, t \in R$$


$$\underline{Ax^* - b} = \underline{Ax^{(1)} - b} + tAp^{(1)}$$

$$\nabla f(x^*) = \nabla f(x^{(1)}) + tAp^{(1)}$$

$$\underline{0} = \underline{\nabla f(x^{(1)}) + tAp^{(1)}}$$

$$0 = p^{(0)T} \nabla f(x^{(1)}) + tp^{(0)T} Ap^{(1)}$$

$$0 = p^{(0)T} Ap^{(1)}$$



共轭



对于二维问题，如何计算 p_1

由于 $-\nabla f(x) \perp p^{(0)}$

并且 $p^{(0)}, \nabla f(x), p^{(1)}$ 共面

所以 $p^{(1)} = -\nabla f(x) + \beta_1 p^{(0)}$

上式两边左乘 $(p^{(0)})^T A$ 得


$$(p^{(0)})^T A p^{(1)} = -(p^{(0)})^T A \nabla f(x) + \beta_1 (p^{(0)})^T A p^{(0)}$$

由于 $p^{(0)}$ 和 $p^{(1)}$ 共轭，得

$$0 = -(p^{(0)})^T A \nabla f(x) + \beta_1 (p^{(0)})^T A p^{(0)}$$

从而

$$\beta_1 = \frac{(p^{(0)})^T A \nabla f(x)}{(p^{(0)})^T A p^{(0)}}$$



对多维问题的推广

二维的迭代格式:

$$\mathbf{x}^* = \mathbf{x}^{(1)} + t\mathbf{p}^{(1)}, t \in R$$

$$t = \frac{(\mathbf{r}^{(k)}, \mathbf{p}^{(k)})}{(A\mathbf{p}^{(k)}, \mathbf{p}^{(k)})}$$

对多维问题的迭代格式:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}$$

不失一般性地设 $\mathbf{x}^{(0)}=\mathbf{0}$, 反复利用上式 有:

$$\mathbf{x}^{(k+1)} = \alpha_0 \mathbf{p}^{(0)} + \alpha_1 \mathbf{p}^{(1)} + \dots + \alpha_k \mathbf{p}^{(k)}$$

现在考虑 $\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots$, 取什么方向?



定义 A 对称正定, 若 R^n 中向量组 $\{p^{(0)}, \dots, p^{(l)}\}$ 满足

$$(Ap^{(i)}, p^{(j)}) = 0, \quad i \neq j$$

则称它为 R^n 中的一个 A -共轭向量组, 或称 A -正交向量组。

注:

- 1、当 $l < n$ 时, 不含零向量的 A -共轭向量组线性无关;
- 2、当 $A = I$ 时, A -共轭性质就是一般的正交性;
- 3、给了一组线性无关的向量, 可以按 $Schmidt$ 正交化的方法得到对应的 A -共轭向量组。




计算 $p^{(k)}$:

$$p^{(1)} = -\nabla f(x) + \beta_1 p^{(0)}$$

取 $p^{(0)}=r^{(0)}$, $p^{(k)}$ 就取为与 $p^{(0)}, \dots, p^{(k-1)}$ A -共轭的向量, 这样的向量不是唯一的, CG法中取 $p^{(k)}$ 为 $r^{(k)}$ 与 $p^{(k-1)}$ 的线性组合, 设

$$p^{(k)} = r^{(k)} + \beta_{k-1} p^{(k-1)}$$



$$\text{利用}(p^{(k)}, Ap^{(k-1)}) = (r^{(k)} + \beta_{k-1} p^{(k-1)}, Ap^{(k-1)})$$

$$= (r^{(k)}, Ap^{(k-1)}) + \beta_{k-1} (p^{(k-1)}, Ap^{(k-1)})$$

$$= 0,$$

可得

$$\beta_{k-1} = -\frac{(r^{(k)}, Ap^{(k-1)})}{(p^{(k-1)}, Ap^{(k-1)})}$$

可以证明这样得到的向量序列 $\{p^{(k)}\}$ 是一个 A -共轭向量组.



计算汇总：

$$\alpha = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$\beta_{k-1} = -\frac{(r^{(k)}, Ap^{(k-1)})}{(p^{(k-1)}, Ap^{(k-1)})}$$

$$p^{(k)} = r^{(k)} + \beta_{k-1}p^{(k-1)}$$

$$\alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$$

$$r^{(k+1)} = b - Ax^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)}$$



公式 α_k 化简

$$\alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)}$$

由上面两式有

$$(r^{(k+1)}, p^{(k)}) = (r^{(k)}, p^{(k)}) - \alpha_k (Ap^{(k)}, p^{(k)}) = 0$$

由 $p^{(k)} = r^{(k)} + \beta_{k-1}p^{(k-1)}$ 有

$$(r^{(k)}, p^{(k)}) = (r^{(k)}, r^{(k)} + \beta_{k-1}p^{(k-1)}) = (r^{(k)}, r^{(k)})$$

从而有：

$$\alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})} = \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

当 $r^{(k)} \neq 0$ 时， $\alpha_k > 0$.



公式 β_k 化简

$$\beta_{k-1} = -\frac{(r^{(k)}, Ap^{(k-1)})}{(p^{(k-1)}, Ap^{(k-1)})}$$

$$Ap^{(k)} = \alpha_k^{-1} (r^{(k+1)} - r^{(k)}) \quad \leftarrow \quad r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)},$$

$$\beta_k = -\frac{(r^{(k+1)}, Ap^{(k)})}{(p^{(k)}, Ap^{(k)})} = -\frac{(r^{(k+1)}, \alpha_k^{-1} (r^{(k)} - r^{(k+1)}))}{(p^{(k)}, Ap^{(k)})}$$

$$= -\frac{\alpha_k^{-1} (r^{(k+1)}, r^{(k+1)})}{(p^{(k)}, Ap^{(k)})} = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})}$$

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

当 $r^{(k+1)} \neq 0$ 时, $\beta_k > 0$.



改进的CG算法：

$$(1) x^{(0)} \in R^{(n)}$$

$$(2) r^{(0)} = b - Ax^{(0)}, p^{(0)} = r^{(0)}$$

$$(3) k = 0, 1, \dots,$$

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})},$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)},$$

$$r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)},$$

$$\beta_k = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})},$$

$$p^{(k+1)} = r^{(k+1)} + \beta_k p^{(k)},$$



注:

(1) 剩余向量相互正交，而 R^n 中至多有 n 个相互正交的非零向量，所以 $r^{(0)}, r^{(1)}, \dots, r^{(n)}$ 中至少有一个向量为零。若 $r^{(k)} = 0$ ，则 $x^{(k)} = x^*$ 。

(2) 实际计算中，由于舍入误差的影响， n 步内得不到准确解，故还需继续迭代。一般因 $p^{(0)}, p^{(1)}, \dots, p^{(n-1)}$ 是一组 A -共轭向量组，继续迭代时，要取 $x^{(0)} = x^{(n)}$ 。

(3) 由误差估计式

$$\|x^{(k)} - x^*\|_A \leq 2 \left[\frac{\sqrt{\text{cond}(A)_2} - 1}{\sqrt{\text{cond}(A)_2} + 1} \right]^k \|x^{(0)} - x^*\|_A$$

当 A 的条件数很小时，共轭斜量法收敛很快，但当 A 是病态严重的矩阵时，共轭斜量法收敛速度很慢。
可采用预处理技术，降低 A 的条件数。



方法对比

最速下降算法:

(1) 选取 $x^{(0)} \in R^n$

(2) 对 $k = 0, 1, 2, \dots$

$$r^{(k)} = b - Ax^{(k)}$$

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ar^{(k)}, r^{(k)})}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k r^{(k)}$$

(3) 当 $\|x^{(k+1)} - x^{(k)}\| < \varepsilon$ 时, 终止迭代。

改进的CG算法:

(1) $x^{(0)} \in R^{(n)}$

(2) $r^{(0)} = b - Ax^{(0)}, p^{(0)} = r^{(0)}$

(3) $k = 0, 1, \dots,$

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})},$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)},$$

$$r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)},$$

$$\beta_k = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})},$$

$$p^{(k+1)} = r^{(k+1)} + \beta_k p^{(k)},$$



方法对比

最速下降法的收敛性结果

$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\|_A \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^k \|\mathbf{x}^{(0)} - \mathbf{x}^*\|_A$$

其中 λ_1, λ_n 分别是对称正定阵 A 的最大、最小特征值, $\|\mathbf{u}\|_A = (A\mathbf{u}, \mathbf{u})^{1/2}$

共轭梯度法的收敛性结果

$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\|_A \leq 2 \left[\frac{\sqrt{\text{cond}(A)_2} - 1}{\sqrt{\text{cond}(A)_2} + 1} \right]^k \|\mathbf{x}^{(0)} - \mathbf{x}^*\|_A$$

当 A 的条件数很小时, 两种方法收敛都很快, 但当 A 是病态严重的矩阵时, 两个方法收敛速度都慢。整体上看, 一般共轭梯度法优于最速下降法。



四、预条件共轭梯度法(PCG)

寻找一个非奇异矩阵C, 使 $\bar{A}=C^{-1}AC^{-T}$ 的条件数比原系数矩阵A的条件数得到改善.

$$Ax = b \Leftrightarrow C^{-1}AC^{-T}C^Tx = C^{-1}b \Leftrightarrow \bar{A}\bar{x} = \bar{b}$$

其中 $\bar{A} = C^{-1}AC^{-T}, \bar{b} = C^{-1}b, \bar{x} = C^Tx,$

令

$$M = CC^T \approx A,$$

$$\bar{A} = C^{-1}AC^{-T} \approx C^{-1}MC^{-T} = C^{-1}CC^TC^{-T}$$

$$= I, \text{cond}(\bar{A})_2 \approx 1$$

令 $M=CC^T$ 称为预优矩阵, 当M接近A时, \bar{A} 接近单位阵, $\text{cond}(\bar{A})_2$ 接近1, 对 $\bar{A}\bar{x} = \bar{b}$ 用共轭斜量法求解, 可达到加速的目的。



预条件共轭梯度法

1、计算 $\bar{A} = C^{-1} A C^{-T}, \bar{b} = C^{-1} b$

2、解 $\bar{A} \bar{x} = \bar{b}$, 得 $\bar{x}^{(k)}$,

$$(1) \bar{x}^{(0)} \in R^{(n)}$$

$$(2) \bar{r}^{(0)} = \bar{b} - \bar{A} \bar{x}^{(0)}, \bar{p}^{(0)} = \bar{r}^{(0)}$$

$$(3) k = 0, 1, \dots,$$

$$\bar{\alpha}_k = \frac{(\bar{r}^{(k)}, \bar{r}^{(k)})}{(\bar{A} \bar{p}^{(k)}, \bar{p}^{(k)})}$$

$$\bar{x}^{(k+1)} = \bar{x}^{(k)} + \bar{\alpha}_k \bar{p}^{(k)},$$

$$\bar{r}^{(k+1)} = \bar{r}^{(k)} - \bar{\alpha}_k \bar{A} \bar{p}^{(k)},$$

$$\bar{\beta}_k = \frac{(\bar{r}^{(k+1)}, \bar{r}^{(k+1)})}{(\bar{r}^{(k)}, \bar{r}^{(k)})}$$

$$\bar{p}^{(k+1)} = \bar{r}^{(k+1)} + \bar{\beta}_k \bar{p}^{(k)}$$

$$3、\bar{x}^{(k)} = C^{-T} x^{(k)}.$$

实际计算，可通过变换，转化成用原方程组的量来计算。



PCG算法：

(1)取初值 $x^{(0)} \in R^{(n)}, r^{(0)} = b - Ax^{(0)},$

(2)解方程组 $Mz^{(0)} = r^{(0)},$ 求出 $z^{(0)},$ 令 $p^{(0)} = z^{(0)}$

(3) $k = 0, 1, \dots,$

$$\alpha_k = \frac{(z^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$$

$$r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)}$$

解方程组 $Mz^{(k+1)} = r^{(k+1)}$

$$\beta_k = \frac{(z^{(k+1)}, r^{(k+1)})}{(z^{(k)}, r^{(k)})}$$

$$p^{(k+1)} = z^{(k+1)} + \beta_k p^{(k)}$$

(4)直到 $\|r^{(k+1)}\| < \varepsilon,$ 输出 $x^{(k+1)}.$

