

# 特征值与特征向量的计算

$$\text{求 } Ax = \lambda x$$

## • 3.1.1 盖氏圆

- 定义3.1-1 设  $A = [a_{ij}]_{n \times n}$ , 称由不等式  $|z - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$  所确定的复区域为  $A$  的第  $i$  行个盖氏圆, 记为  $G_i$ :

$$G_i = \{z : |z - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \}, \quad i = 1, 2, \dots, n.$$

- 定理3.1-1 若  $\lambda$  为  $A$  的特征值, 则  $\lambda \in \bigcup_{i=1}^n G_i$




## 例1 估计方阵特征值的范围

$$A = \begin{bmatrix} 1 & 0.1 & 0.2 & 0.3 \\ 0.5 & 3 & 0.1 & 0.2 \\ 1 & 0.3 & -1 & 0.5 \\ 0.2 & -0.3 & -0.1 & -4 \end{bmatrix}$$

解：

$$G_1 = \{z: |z - 1| \leq 0.6\}; \quad G_2 = \{z: |z - 3| \leq 0.8\};$$

$$G_3 = \{z: |z + 1| \leq 1.8\}; \quad G_4 = \{z: |z + 4| \leq 0.6\}.$$



注：定理称  $A$  的  $n$  个特征值全落在  $n$  个盖氏圆上，但未说明每个圆盘内都有一个特征值。



## § 1 幂法和反幂法

引例 设矩阵  $A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$ ，用特征方程容易求得  $A$  的两个特征值为

$$\lambda_1 = -1, \quad \lambda_2 = 3.$$

取初始向量  $x^{(0)} = (1, 0)^T$ ，计算向量序列

$$x^{(k+1)} = Ax^{(k)}, \quad k = 0, 1, \dots$$

具体结果如下表所示：



# 引例

幂法计算结果

| $k$ | $x_1^{(k)}$ | $x_2^{(k)}$ |
|-----|-------------|-------------|
| 0   | 1           | 0           |
| 1   | 1           | 2           |
| 2   | 5           | 4           |
| 3   | 13          | 14          |
| 4   | 41          | 40          |
| 5   | 121         | 122         |
| 6   | 365         | 364         |
| 7   | 1093        | 1094        |



# 引例

考察两个相邻向量对应分量之比:

$$\frac{x_1^{(2)}}{x_1^{(1)}} = 5$$

$$\frac{x_1^{(3)}}{x_1^{(2)}} = 2.6$$

$$\frac{x_1^{(4)}}{x_1^{(3)}} = 3.154$$

$$\frac{x_1^{(5)}}{x_1^{(4)}} = 2.951$$

$$\frac{x_1^{(6)}}{x_1^{(5)}} = 3.016$$

$$\frac{x_1^{(7)}}{x_1^{(6)}} = 2.994$$

$$\frac{x_2^{(2)}}{x_2^{(1)}} = 2$$

$$\frac{x_2^{(3)}}{x_2^{(2)}} = 3.5$$

$$\frac{x_2^{(4)}}{x_2^{(3)}} = 2.857$$

$$\frac{x_2^{(5)}}{x_2^{(4)}} = 3.05$$


$$\frac{x_2^{(6)}}{x_2^{(5)}} = 2.983$$

$$\frac{x_2^{(7)}}{x_2^{(6)}} = 3.005$$



# 引例

考察两个相邻向量对应分量之比：



矩阵  $A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$  的特征值为 -1 和 3.



# § 1 幂法和反幂法

## 1.1 幂法

用于求矩阵的按模最大的特征值与相应的特征向量的近似值。

设  $A$  为  $n$  阶实矩阵,  $\lambda_i, u_i$  ( $i = 1, 2, \dots, n$ ) 为  $A$  的特征值和相应的特征向量,

$$\text{且满足: } |\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$$

$u_1, u_2, \dots, u_n$ , 线性无关.



对任意向量  $\boldsymbol{x}^{(0)}$ , 有  $\boldsymbol{x}^{(0)} = \sum_{i=1}^n \alpha_i \boldsymbol{u}_i$ ,  $\alpha_i$  不全为零 .

$$\boldsymbol{x}^{(k+1)} = A\boldsymbol{x}^{(k)} = A^{k+1}\boldsymbol{x}^{(0)}$$

$$= \sum_{i=1}^n A^{k+1} \alpha_i \boldsymbol{u}_i = \sum_{i=1}^n \alpha_i \lambda_i^{k+1} \boldsymbol{u}_i$$

$$= \lambda_1^{k+1} \left[ \alpha_1 \boldsymbol{u}_1 + \left( \frac{\lambda_2}{\lambda_1} \right)^{k+1} \alpha_2 \boldsymbol{u}_2 + \cdots + \left( \frac{\lambda_n}{\lambda_1} \right)^{k+1} \alpha_n \boldsymbol{u}_n \right]$$

$$\approx \lambda_1^{k+1} \alpha_1 \boldsymbol{u}_1$$





定理：设  $A \in R^{n \times n}$ ，特征值  $\lambda_i$  ( $i = 1, 2, \dots, n$ ) 满足

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|,$$

且与  $\lambda_i$  对应的特征向量  $u_1, u_2, \dots, u_n$  线性无关，则对任意非零初始向量  $x^{(0)}$  ( $\alpha_1 \neq 0$ )，向量序列

$$x^{(k)} = A^k x^{(0)} \rightarrow \lambda_1^k \alpha_1 u_1, \quad \frac{x_i^{(k+1)}}{x_i^{(k)}} \rightarrow \lambda_1 (k \rightarrow \infty).$$

相应的特征向量为  $x^{(k+1)}$ .

注：  $x^{(k+1)} \approx \lambda_1^{k+1} \alpha_1 u_1$ ，实际计算时将  $x^{(k+1)}$  标准化。



标准化： 设与  $\lambda_1$  对应的特征向量  $u_1$

若  $x = (x_1, x_2, \dots, x_n)$ ,  $|x_r| = \max_{1 \leq i \leq n}(|x_i|)$ , 记  $x_r = \max(x)$

取初始向量  $x^{(0)}$ , 将  $x^{(0)}$  标准化为  $y^{(0)}$

$$\begin{cases} x^{(k)} = Ay^{(k-1)} \\ y^{(k)} = \frac{x^{(k)}}{\max(x^{(k)})}, \quad k = 1, 2, \dots \end{cases}$$

则  $y^{(k)} \rightarrow \frac{u_1}{\max(u_1)}, \quad \max(x^{(k)}) \rightarrow \lambda_1 (k \rightarrow \infty)$



## 算法4.1

1. 输入  $A$ , 初始向量  $x$ , 误差限  $\varepsilon$ , 最大迭代次数  $N$ ;
2. 置  $k=1$ ,  $\lambda = \max(x)$ ;  $y = \frac{x}{\lambda}$ ;
3. 计算  $x = Ay$ ,  $\beta = \max(x)$ ,  $y = \frac{x}{\beta}$ ;
4. 若  $|\lambda - \beta| < \varepsilon$ , 输出  $\beta, y$ , 停机; 否则, 转5;
5. 若  $k < N$ , 置  $k = k + 1, \lambda = \beta$ , 转3, 否则输出失败信息, 停机.



## 幂法适用范围:

求大型稀疏矩阵按模最大的特征值 $\lambda_1$ .

矩阵的特征值分布为,  $|\lambda_1| > |\lambda_{m+1}| \geq \cdots \geq |\lambda_n|$

$\lambda_1$  为单根或重根, 即  $\lambda_1 = \cdots \lambda_m$ ,

矩阵有 $n$ 个线性无关的特征向量.



例：用幂法求矩阵  $A$  按模最大特征值和相应的特征向量 ( $\varepsilon=10^{-4}$ )

$$A = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix} \quad \begin{cases} m_k = \max_i |x_i^{(k)}| = \|x^{(k)}\|, \\ y_i^{(k)} = x_i^{(k)} / m_k, \\ x^{(k+1)} = Ay^{(k)}. \end{cases}$$

| $k$         | 0      | 1      | 2       | 3       | 4       | 5        | 6       |
|-------------|--------|--------|---------|---------|---------|----------|---------|
| $x_i^{(k)}$ | 1.0000 | 1.0000 | 2.0000  | 3.0000  | 2.5000  | 2.4286   | 2.4167  |
|             | 1.0000 | 0.0000 | -2.0000 | -4.0000 | -3.5000 | -3.1286  | -3.4167 |
|             | 1.0000 | 1.0000 | 2.0000  | 3.0000  | 2.5000  | -2.4286  | 2.4167  |
| $m_k$       | 1.0000 | 1.000  | 2.0000  | 4.0000  | 3.5000  | 3.428570 | 3.4167  |
| $y_i^{(k)}$ | 1.0000 | 1.0000 | 1.0000  | 0.7500  | 0.7143  | 0.7083   | 0.7073  |
|             | 1.0000 | 1.0000 | -1.0000 | -1.0000 | -1.0000 | -1.0000  | -1.0000 |
|             | 1.0000 | 1.0000 | 1.0000  | 0.7500  | 0.7143  | 0.7083   | 0.7073  |

矩阵的最大特征值为  $\lambda_1 = 2 + \sqrt{2}$  其对应的特征向量  $u_1 = (\frac{\sqrt{2}}{2}, -1, \frac{\sqrt{2}}{2})^T$



幂法的收敛速度取决于比值  $r = \left| \frac{\lambda_2}{\lambda_1} \right|$ , 比值越小, 收敛越快.

## 1.2 幂法的加速

### (一) 原点移位法

$\lambda_i$  是  $A$  的特征值, 则  $\lambda_i - \lambda_0$  是  $A - \lambda_0 I$  的特征值

$$\begin{aligned} x^{(k+1)} &= (A - \lambda_0 I)x^{(k)} \\ &= (\lambda_1 - \lambda_0)^{k+1} [\alpha_1 u_1 + \left(\frac{\lambda_2 - \lambda_0}{\lambda_1 - \lambda_0}\right)^{k+1} \alpha_2 u_2 + \cdots \left(\frac{\lambda_n - \lambda_0}{\lambda_1 - \lambda_0}\right)^{k+1} \alpha_n u_n] \end{aligned}$$



设  $A$  有特征值  $\lambda_i$ , 且  $|\lambda_1| > |\lambda_2| > \dots$ , 取  $\lambda_0$  使得

$$|\lambda_1 - \lambda_0| > |\lambda_i - \lambda_0| \quad \text{且} \quad \frac{\max_{i \neq 1} |\lambda_i - \lambda_0|}{|\lambda_1 - \lambda_0|} < \left| \frac{\lambda_2}{\lambda_1} \right|$$

用幂法求  $A - \lambda_0 I$  的按模最大的特征值  $\lambda_1^*$ , 则  $\lambda_1 = \lambda_1^* + \lambda_0$ , 这种方法称为原点移位法.

注: 实际应用时,  $A$  的特征值不知道,  $\lambda$  无法确定, 当收敛速度慢时, 可以适当移动原点.





例：计算矩阵  $A = \begin{bmatrix} 1.0 & 1.0 & 0.5 \\ 1.0 & 1.0 & 0.25 \\ 0.5 & 0.25 & 2.0 \end{bmatrix}$  按模取最大的特征值

先用规范化的幂法计算：

| $k$ | $y^{(k)} = x^{(k)} / \max(x^{(k)})$ | $\lambda_1 \approx \max(x^{(k)})$ |
|-----|-------------------------------------|-----------------------------------|
| 0   | (1, 1, 1)                           |                                   |
| 1   | (0.9091, 0.8182, 1) <sup>T</sup>    | 2.75                              |
| 19  | (0.7482, 0.6497, 1) <sup>T</sup>    | 2.5365374                         |
| 20  | (0.7482, 0.6497, 1) <sup>T</sup>    | 2.5365323                         |

采用原点位移的加速法求解,取  $\lambda_0 = 0.75$ , 矩阵  $B = A - \lambda_0 I$

| $k$ | $y^{(k)} = x^{(k)} / \max(x^{(k)})$ | $\lambda_1 \approx \max(x^{(k)})$ |
|-----|-------------------------------------|-----------------------------------|
| 0   | (1, 1, 1) <sup>T</sup>              |                                   |
| 9   | (0.7483, 0.6497, 1) <sup>T</sup>    | 1.7866587                         |
| 10  | (0.7483, 0.6497, 1) <sup>T</sup>    | 1.7865914                         |

由以上两表得到：  $\lambda_1 = \mu_1 + \lambda_0 \approx 2.5365914$





## (二)幂法的埃特肯 (**Aitken**) 加速

若  $\{a_k\}$  收敛与  $a$ , 且  $\lim_{k \rightarrow \infty} \frac{a_{k+1} - a}{a_k - a} = c \neq 0$  即  $\{a_k\}$  线性收敛,

当  $k$  充分大时, 有  $\frac{a_{k+1} - a}{a_k - a} \approx \frac{a_{k+2} - a}{a_{k+1} - a}$

$$y_{n+2} = x_{n+2} - \frac{(x_{n+2} - x_{n+1})^2}{x_{n+2} - 2x_{n+1} + x_n}$$

$$\Rightarrow a \approx a_k - \frac{(a_{k+1} - a_k)^2}{a_{k+2} - 2a_{k+1} + a_k} := \hat{a}_k$$

用  $\hat{a}_k$  逼近  $a$ , 这种方法称为 *Aitken* 加速法.



## 算法4.2

1. 输入  $A = (a_{ij})$ , 初始向量  $x$ , 误差限  $\varepsilon$ , 最大迭代次数  $N$ ,
2. 置  $k = 1$ ,  $\alpha_0 = 0$ ,  $\alpha_1 = 0$ ,  $\lambda_0 = 1.0$ ,  $y = \frac{x}{\max(x)}$ ,
3. 计算  $x = Ay$ , 置  $\max(x) \Rightarrow \alpha_2$ ,  $\frac{x}{\max(x)} \Rightarrow y$ ,
4. 计算  $\lambda = \alpha_0 - \frac{(\alpha_1 - \alpha_0)^2}{\alpha_2 - 2\alpha_1 + \alpha_0}$ ,
5. 若  $|\lambda - \lambda_0| < \varepsilon$ , 输出  $\lambda, y$  停机, 否则转6,
6. 若  $k < N$ , 置  $\alpha_1 \Rightarrow \alpha_0$ ,  $\alpha_2 = \alpha_1$ ,  $\lambda \Rightarrow \lambda_0$ ,  $k+1 \Rightarrow k$ , 转3, 否则, 输出失败信息, 停机.



### (三) 对称矩阵的Rayleigh商加速法

- 定义： 设 $A$ 对称， $x \neq 0$ ，则称  $R(x) = \frac{x^T A x}{x^T x}$  为  $x$  关于  $A$  的 Rayleigh 商。

$$R(y^{(k)}) = \frac{(A^k x^{(0)})^T A^{k+1} x^{(0)}}{(A^k x^{(0)})^T A^k x^{(0)}} = \frac{\sum_{j=1}^n \alpha_j^2 \lambda_j^{2k+1}}{\sum_{j=1}^n \alpha_j^2 \lambda_j^{2k}} \approx \lambda_1 + O\left(\left(\frac{\lambda_2}{\lambda_1}\right)^{2k}\right)$$



• 公式

$$\left\{ \begin{array}{l} y^{(k)} = \frac{x^{(k)}}{\max(x^{(k)})} = \frac{A^k x^{(0)}}{\max(A^k x^{(0)})} \\ x^{(k+1)} = Ay^{(k)} = \frac{A^{k+1} x^{(0)}}{\max(A^k x^{(0)})} \\ R(y^{(k)}) = \frac{(y^{(k)})^T Ay^{(k)}}{(y^{(k)})^T (y^{(k)})} = \frac{(A^k x^{(0)})^T A^{k+1} x^{(0)}}{(A^k x^{(0)})^T A^k x^{(0)}} \end{array} \right.$$

称为Rayleigh

商加速法。

此外

$$R(y^{(k)}) \rightarrow \lambda_1, \quad y^{(k)} \rightarrow \frac{v_1}{\max(v_1)}$$



- 注：有了  $R(x^{(k)})$ ,  $R(x^{(k+1)})$ ,  $R(x^{(k+2)})$ , 的值，可再用Aitken加速法得到的一个更好的近似值.

因为

$$\frac{R(x^{(k+2)}) - \lambda_1}{R(x^{(k+1)}) - \lambda_1} \approx \frac{R(x^{(k+1)}) - \lambda_1}{R(x^{(k)}) - \lambda_1}$$

所以

$$\lambda_1 \approx R(x^{(k+2)}) - \frac{[R(x^{(k+2)}) - R(x^{(k+1)})]^2}{R(x^{(k+2)}) - 2R(x^{(k+1)}) + R(x^{(k)})} = \lambda_1^{(k+2)}$$



例：设  $A = \begin{pmatrix} 1 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 3 \end{pmatrix}$ ，用瑞利商加速法求  $A$  的最大模特征值及特征向量，并与幂法相比较。

解：编程计算结果如下：

| 原始的幂法 |        |   |        | <u>Aitken</u> 加速法 |        | Rayleigh 加速法 |        |
|-------|--------|---|--------|-------------------|--------|--------------|--------|
| 1     | 5.1667 | 6 | 5.1334 | 1                 | 5.1613 | 1            | 5.1299 |
| 2     | 5.1613 | 7 | 5.1330 | 2                 | 5.1690 | 2            | 5.1322 |
| 3     | 5.1437 | 8 | 5.1328 | 3                 | 5.1336 | 3            | 5.1326 |
| 4     | 5.1373 | 9 | 5.1327 | 4                 | 5.1326 | 4            | 5.1326 |
| 5     | 5.1346 |   |        | 5                 | 5.1326 |              |        |



## 反幂法：

基本思想： $Ax = \lambda x \Rightarrow x = A^{-1}(\lambda x)$ , 则  $A^{-1}x = \frac{1}{\lambda}x$

(1)  $A$  与  $A^{-1}$  的特征值互为倒数, 特征向量不变, 求  $A$  的按模最小的特征值  $\lambda_n$

$\Leftrightarrow$  求  $A^{-1}$  的按模最大的特征值  $\frac{1}{\lambda_n}$ .

(2) 计算  $x^{(k+1)} = A^{-1}y^{(k)} \Leftrightarrow$  解方程组  $Ax^{(k+1)} = y^{(k)}$



### 算法4.3（反幂法）

1. 输入矩阵  $A$ , 近似值  $\lambda^*$ , 初始向量  $x$ , 误差限  $\varepsilon$ , 最大迭代次数  $N$ ,
2. 置  $k = 1, \lambda_0 = 1, y = \frac{x}{\max(x)}$ ,
3. 作三角分解  $(A - \lambda^* I) = LU$
4. 解方程组  $LUx = y (Lz = y, Ux = z)$ ,
5.  $\mu = \max(x), y = \frac{x}{\max(x)}, \lambda = \lambda^* + \frac{1}{\mu}$
6. 若  $|\lambda - \lambda_0| < \varepsilon$ , 输出  $\lambda, y$ , 停机, 否则转 7,
7. 若  $k < N$ , 置  $k + 1 \Rightarrow k, \lambda \Rightarrow \lambda_0$ , 转 4; 否则输出失败信息, 停机.





例：用反幂法求矩阵  $A = \begin{bmatrix} 2 & -1 & 0 \\ 0 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$  求按模最小的特征

值及特征向量, 取  $x^{(0)} = (0, 0, 1)^T$ ;

解：求  $A$  按模最小的特征值及其特征向量

用反幂法

$$x^{(k+1)} = A^{-1} y^{(k)} \Leftrightarrow Ax^{(k+1)} = y^{(k)}$$

将  $A$  进行  $LU$  分解,

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -\frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 2 & -1 & 0 \\ 0 & 2 & -1 \\ 0 & 0 & \frac{3}{2} \end{bmatrix} = LU$$



$$\mathbf{y}^{(0)} = \mathbf{x}^{(0)} = (0, 0, 1)^T$$

$$\mathbf{x}^{(1)} = A^{-1} \mathbf{y}^{(0)} \Leftrightarrow L U \mathbf{x}^{(1)} = \mathbf{y}^{(0)}$$

$$L \mathbf{z} = \mathbf{y}^{(0)} \Rightarrow \mathbf{z} = (0, 0, 1)^T$$

$$U \mathbf{x}^{(1)} = \mathbf{z} \Rightarrow \mathbf{x}^{(1)} = \left(\frac{1}{6}, \frac{1}{3}, \frac{2}{3}\right)^T$$

$$\mu = \frac{2}{3}$$

$$L = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -\frac{1}{2} & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 2 & -1 & 0 \\ 0 & 2 & -1 \\ 0 & 0 & \frac{3}{2} \end{bmatrix}$$

$$\lambda^{(1)} = \frac{1}{\mu} = 1.5 \quad \mathbf{y}^{(1)} = \left(\frac{1}{4}, \frac{1}{2}, 1\right)^T$$

$$L \mathbf{z} = \mathbf{y}^{(1)} \Rightarrow \mathbf{z} = \left(\frac{1}{4}, \frac{1}{2}, \frac{5}{4}\right)^T$$

$$U \mathbf{x}^{(2)} = \mathbf{z} \Rightarrow \mathbf{x}^{(2)} = \left(\frac{11}{24}, \frac{2}{3}, \frac{5}{6}\right)^T$$

$$\mu = \frac{5}{6}$$

$$\lambda^{(2)} = \frac{1}{\mu} = 1.2 \quad \mathbf{y}^{(2)} = \left(\frac{11}{20}, \frac{4}{5}, 1\right)^T$$



| <b>k</b>      | <b>lambda</b> | <b>x1</b>     | <b>x2</b>     | <b>x3</b>     | <b>err</b>    |
|---------------|---------------|---------------|---------------|---------------|---------------|
| <b>1.0000</b> | <b>1.5000</b> | <b>0.2500</b> | <b>0.5000</b> | <b>1.0000</b> | <b>1.5000</b> |
| <b>2.0000</b> | <b>1.2000</b> | <b>0.5500</b> | <b>0.8000</b> | <b>1.0000</b> | <b>0.3000</b> |
| <b>3.0000</b> | <b>1.0714</b> | <b>0.7589</b> | <b>0.9286</b> | <b>1.0000</b> | <b>0.1286</b> |
| <b>4.0000</b> | <b>1.0244</b> | <b>0.8765</b> | <b>0.9756</b> | <b>1.0000</b> | <b>0.0470</b> |
| <b>5.0000</b> | <b>1.0082</b> | <b>0.9378</b> | <b>0.9918</b> | <b>1.0000</b> | <b>0.0162</b> |
| <b>6.0000</b> | <b>1.0027</b> | <b>0.9688</b> | <b>0.9973</b> | <b>1.0000</b> | <b>0.0055</b> |
| <b>7.0000</b> | <b>1.0009</b> | <b>0.9844</b> | <b>0.9991</b> | <b>1.0000</b> | <b>0.0018</b> |
| <b>8.0000</b> | <b>1.0003</b> | <b>0.9922</b> | <b>0.9997</b> | <b>1.0000</b> | <b>0.0006</b> |



反幂法求在  $\tilde{\lambda}$  附近的特征值:

由于  $A - \tilde{\lambda}I$  的最小特征值是与  $\tilde{\lambda}$  最为接近的特征值. 若假设  $A - \tilde{\lambda}I$  的最小特征值为  $\mu$ , 则与其最为接近的特征值近似值为  $\tilde{\lambda} + \mu$ . 设与  $\tilde{\lambda}$  最接近的特征值为  $\lambda_i$

$$|\lambda_i - \tilde{\lambda}| \ll |\lambda_j - \tilde{\lambda}|, j \neq i, j = 1, \dots, n$$

作矩阵  $A - \tilde{\lambda}I$ , 它的特征值及相应特征向量为:

$$\mu_j = \lambda_j - \tilde{\lambda} \text{ 和 } u_j, j = 1, \dots, n$$

若用反幂法求  $A - \tilde{\lambda}I$  的最小特征值, 则有如下计算关系:

$$(A - \tilde{\lambda}I)x_{k+1} = x_k, k = 0, 1, \dots$$



于是得矩阵  $A$  在  $\tilde{\lambda}$  附近特征值和相应特征向量为:

$$\begin{cases} \lambda_i = \tilde{\lambda} + \mu_i \approx \tilde{\lambda} + \frac{x_i^{(k)}}{x_i^{(k+1)}}, \\ u_i \approx x_{k+1}. \end{cases}$$



引例：用反幂法求矩阵

$$A = \begin{pmatrix} 2 & -2 & 0 \\ 0 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}$$

在2.93附近的特征值及相应特征向量（精度 $\varepsilon = 10^{-5}$ ）。

解：对矩阵  $A - 2.93I$  作三角分解：

$$A - 2.93I = \begin{pmatrix} -0.93 & -1 & 0 \\ 0 & -0.93 & -1 \\ 0 & -1 & -0.93 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & \frac{1}{0.93} & 1 \end{pmatrix} \begin{pmatrix} -0.93 & -1 & 0 \\ 0 & -0.93 & -1 \\ 0 & 0 & -0.93 + \frac{1}{0.93} \end{pmatrix}.$$



取  $x_0 = (0, 0, 1)^T$ ，由迭代公式计算结果如下表：

表 4.8 反幂法的计算

| $k$         | 0       | 1        | 2         | 3         |
|-------------|---------|----------|-----------|-----------|
| $x_i^{(k)}$ | 0.00000 | 7.95906  | 12.69231  | 14.27843  |
|             | 1.00000 | -7.40192 | -12.80385 | -14.26763 |
|             | 1.00000 | 6.88379  | 12.83758  | 14.26627  |
| $m_k$       | 1.00000 | 7.95906  | 12.83758  | 14.26627  |
| $y_i^{(k)}$ | 0.00000 | 1.00000  | 0.98868   | 1.00000   |
|             | 0.00000 | -0.93000 | -0.99737  | -0.99924  |
|             | 1.00000 | 0.86490  | 1.00000   | 0.99915   |
| $z_i^{(k)}$ | 0.00000 | 1.00000  | 0.98868   | 1.00000   |
|             | 0.00000 | -0.93000 | -0.99737  | -0.99924  |
|             | 1.00000 | 1.86490  | 2.07244   | 2.07360   |



# 求矩阵全部特征值的QR方法

60年代出现的QR算法是目前计算中小型矩阵的全部特征值与特征向量的最有效方法。 **理论依据：**任一非奇异实矩阵都可分解成一个正交矩阵 $Q$ 和一个上三角矩阵 $R$ 的乘积，而且当 $R$ 的对角元符号取定时，分解是唯一的。

QR方法的基本思想是利用矩阵的QR分解通过迭代格式

$$\begin{cases} A_k = Q_k R_k \\ A_{k+1} = R_k Q_k \end{cases} \quad (k = 1, 2, \dots).$$

将 $A=A_1$ 化成相似的上三角阵（或分块上三角阵），从而求出矩阵 $A$ 的全部特征值与特征向量。





由  $A = A_1 = Q_1 R_1$ , 即  $Q_1^{-1} A = R_1$ 。

于是  $A_2 = R_1 Q_1 = Q^{-1} A Q_1$ , 即  $A_2$  与  $A$  相似。

同理可得,  $A_k \sim A$  ( $k = 2, 3, \dots$ )。

故它们有相同的特征值。

可证, 在一定条件下, 基本QR方法产生的矩阵序列  $\{A_k\}$  “基本”收敛于一个上三角阵（或分块上三角阵）。即主对角线（或主对角线子块）及其以下元素均收敛, 主对角线（或主对角线子块）以上元素可以不收敛。

特别的, 如果  $A$  是实对称阵, 则  $\{A_k\}$  “基本”收敛于对角矩阵。



## § 2 吉文斯(Givens)旋转变换

正交变换，进行矩阵对角化，求解一般矩阵所有特征值。

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$$

例 设旋转矩阵 $R$ 为

$$R = \begin{pmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{pmatrix}$$



$$\mathbf{B} = \mathbf{R}\mathbf{A}\mathbf{R}^T = \begin{pmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{pmatrix} \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} \triangleq \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{pmatrix}$$

比较系数，有

$$b_{11} = a_{11} \cos^2 \theta + a_{22} \sin^2 \theta + a_{12} \sin 2\theta$$

$$b_{12} = b_{21} = \frac{1}{2}(a_{22} - a_{11}) \sin 2\theta + a_{12} \cos 2\theta$$

$$b_{22} = a_{11} \sin^2 \theta + a_{22} \cos^2 \theta - a_{12} \cos 2\theta$$

为使 $\mathbf{A}$ 的相似矩阵 $\mathbf{B}$ 成为对角阵，只须适当选取 $\theta$ ，使

$$b_{12} = b_{21} = \frac{1}{2}(a_{22} - a_{11}) \sin 2\theta + a_{12} \cos 2\theta = 0$$



若  $a_{11} = a_{22}$  时, 取  $|\theta| \leq \frac{\pi}{4}$ ;

若  $a_{11} \neq a_{22}$ , 则有  $\operatorname{tg} 2\theta = \frac{2a_{12}}{a_{11} - a_{22}}$ , 此时  $|\theta| \leq \frac{\pi}{4}$  .

从而旋转矩阵  $R$  确定.  $A$  的特征值为:

$$\lambda_1 = b_{11}, \quad \lambda_2 = b_{22}$$

计算可得对应于  $\lambda_1$ ,  $\lambda_2$  的特征向量是

$$x_1 = (\cos \theta, \sin \theta)^T, \quad x_2 = (-\sin \theta, \cos \theta)^T$$



$n$ 阶矩阵的吉文斯旋转变换：给定

$$P(i, j) = \begin{pmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & 1 & & & \\ & & \cos \theta & \sin \theta & & \\ & & & 1 & & \\ & & & & \ddots & \\ & & & & & 1 \\ & & -\sin \theta & \cos \theta & & \\ & & & & & \ddots & \\ & & & & & & 1 \end{pmatrix}$$

$i \qquad j$

一般的吉文斯旋转变换矩阵：

$$\begin{cases} P_k(p, p) = P_k(q, q) = \cos \theta, \\ P_k(p, q) = -P_k(q, p) = \sin \theta, \\ P_k(i, i) = 1, \quad P_k(i, j) = 0, \quad i, j \neq p, q. \end{cases}$$



## 高效计算 $\sin(\theta)$ 和 $\cos(\theta)$ :

当  $|\theta| \leq \frac{\pi}{4}$  时, 由三角恒等式有:

$$2 \cos^2 \theta - 1 = \cos 2\theta = \frac{1}{\sqrt{1 + \operatorname{tg}^2 2\theta}} = \frac{y}{\sqrt{x^2 + y^2}}$$

$$2 \cos^2 \theta = 1 + \frac{y}{\sqrt{x^2 + y^2}}$$

$\cos \theta$  始终取正值.

为避免精度不高, 可采用

$$\sin 2\theta = 2 \sin \theta \cos \theta = \operatorname{tg} 2\theta \cdot \cos 2\theta = \frac{x}{\sqrt{x^2 + y^2}}$$

即

$$\sin \theta = \frac{\sin 2\theta}{2\sqrt{(1 + \cos 2\theta) / 2}}.$$



可以证明:

设矩阵  $A \in \mathbf{R}^{n \times n}$  是对称矩阵, 记  $A_0 = A$ , 对  $A$  作一系列旋转相似变换, 即

$$A_k = P_k A_{k-1} P_k^T, (k = 1, 2, \dots)$$

其中  $A_k$  ( $k = 1, 2, \dots$ ) 仍是对称矩阵, 且逐渐趋于对角矩阵.



**引例** 设矩阵  $A = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}$ ，用吉文斯旋转变换求  $A$  的所有特征值和特征向量.

**解：**  $A$  实对称，使用 **Givens** 变换，取旋转矩阵  $P_{12}(\pi / 4)$  .

因为对  $|a_{21}| = \max\{|a_{21}|, |a_{31}|\}$ ，则有

$$A^{(1)} = P_{12}^T A P_{12} = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 2 \end{pmatrix} \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & -\frac{1}{\sqrt{2}} \\ 0 & 3 & -1 \\ -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 2 \end{pmatrix}$$





同理取  $P_{13}(\theta)$  , 其中  $\theta = \frac{1}{2} \arctan \frac{2a_{13}^{(1)}}{a_{11}^{(1)} - a_{33}^{(1)}} = \frac{1}{2} \arctan \sqrt{2}$

得 
$$A^{(2)} = P_{13}^T A P_{13} = \begin{pmatrix} 0.63398 & -0.32505 & 0 \\ -0.32505 & 3 & -0.62797 \\ 0 & -0.62797 & 2.36603 \end{pmatrix}$$

反复计算有 
$$A^{(k)} = \begin{pmatrix} 0.58578 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3.41421 \end{pmatrix}$$

故  $A$  的所有特征值为:

$$\lambda_1 = 0.58578, \lambda_2 = 2, \lambda_3 = 3.41421.$$



此外

$$P = P_{12}P_{13} \cdots P_k = \begin{pmatrix} 0.5 & 0.7071 & 0.5 \\ 0.7071 & 0 & -0.7071 \\ 0.5 & -0.7071 & 0.5 \end{pmatrix}$$

于是 $\lambda_1$ ,  $\lambda_2$ ,  $\lambda_3$ 对应的3个特征向量为:

$$x_1 = \begin{pmatrix} 0.5 \\ 0.7071 \\ 0.5 \end{pmatrix}, \quad x_2 = \begin{pmatrix} 0.7071 \\ 0 \\ -0.7071 \end{pmatrix}, \quad x_3 = \begin{pmatrix} 0.5 \\ -0.7071 \\ 0.5 \end{pmatrix}$$

$A$ 的准确特征值为:  $\lambda_1 = 2 - \sqrt{2}$ ,  $\lambda_2 = 2$ ,  $\lambda_3 = 2 + \sqrt{2}$



### § 3 豪斯霍尔德 (Householder) 变换

定义: 设  $v \in R_*^n = R^n - \{0\}$ ,  $n$  阶豪斯霍尔德矩阵  $H = H(v)$

$$H = I - \frac{2}{v^T v} v v^T$$

$I$  为  $n$  阶单位阵. 显然, 对任意  $x \in R^n$

$$Hx = x - 2 \frac{v^T x}{v^T v} v, \quad v^T Hx = -v^T x$$




图 4.3 镜面反射图



**定理:** 设  $b, u \in R_*^n$ ,  $b \neq u$ ,  $\|b\|_2 = \|u\|_2$ , 则存在豪斯霍尔德阵  $H$ , 使得  $Hb = u$ .

**证明:** 取  $v = b - u \in R_*^n$  令  $H = I - \frac{2}{v^T v} vv^T$

$$\begin{aligned} \text{且 } Hb &= b - \frac{2(b-u)(b-u)^T}{(b-u)^T(b-u)}b \\ &= b - \frac{2(b-u)^T b (b-u)}{b^T b - b^T u - u^T b + u^T u}. \end{aligned}$$

因为  $\|b\|_2 = \|u\|_2$  所以  $b^T b = u^T u$ .



又因为  $b^T u = \sum_{i=1}^n b_i u_i = u^T b$  故

$$Hb = b - \frac{2(b^T b - u^T b)}{2(b^T b - u^T b)}(b - u) = b - (b - u) = u.$$

如何确定  $H$ ?

取

$$b = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_r \\ b_{r+1} \\ \vdots \\ b_n \end{pmatrix}$$

$$u = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_r \\ u_{r+1} \\ \vdots \\ u_n \end{pmatrix}$$

$$v = b - u = \begin{pmatrix} b_1 - u_1 \\ b_2 - u_2 \\ \vdots \\ b_r - u_r \\ b_{r+1} - u_{r+1} \\ \vdots \\ b_n - u_n \end{pmatrix}$$

$$H = I - \frac{2}{v^T v} v v^T$$



比如

$$b = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_r \\ b_{r+1} \\ \vdots \\ b_n \end{pmatrix} \quad u = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_r \\ u_{r+1} \\ \vdots \\ 0 \end{pmatrix} \quad \text{令} \quad u_i = \begin{cases} b_i & i = 1, \dots, r, \\ -\text{sign}(b_{r+1}) \sqrt{b_{r+1}^2 + \dots + b_n^2}, & i = r + 1, \\ 0, & i = r + 2, \dots, n. \end{cases}$$

满足  $u \neq b \in R_*$  且  $\|u\|_2 = \|b\|_2$ .



**定理：** 设  $A \in R^{n \times n}$  为对称矩阵，则存在豪斯霍尔德阵

$H_1, H_2, \dots, H_k$  ( $k \leq n-2$ )，使由递推公式

$$A_1 = A \quad A_{i+1} = H_i A_i H_i \quad (i = 1, \dots, k)$$

得到的对称矩阵  $A_{k+1}$  为三对角阵.

引例：用豪斯霍尔德变换将对称阵  $A = \begin{pmatrix} 6 & 2 & 3 & 1 \\ 2 & 5 & 4 & 8 \\ 3 & 4 & 9 & 1 \\ 1 & 8 & 1 & 7 \end{pmatrix}$   
化为三对角矩阵.



解：当  $n = 4$ ，则至多通过  $n - 2 = 4 - 2 = 2$  次豪斯霍尔德变换可将对称阵  $A$  化为三对角阵。

$$\text{令 } A_1 = A, \text{ 记 } b_1 = \begin{pmatrix} 6 \\ 2 \\ 3 \\ 1 \end{pmatrix} \quad \text{取 } u_1 = \begin{pmatrix} 6 \\ -\sqrt{2^2 + 3^2 + 1^2} \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 6 \\ -\sqrt{14} \\ 0 \\ 0 \end{pmatrix}$$

$$\text{则 } v_1 = b_1 - u_1 = \begin{pmatrix} 0 \\ 2 + \sqrt{14} \\ 3 \\ 1 \end{pmatrix}, \quad \|v_1\|_2^2 = 42.9666.$$





$$H_1 = I - 2 \frac{v_1 v_1^T}{\|v_1\|_2^2} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & -0.5345 & -0.8018 & -0.2673 \\ 0 & -0.8018 & -0.5811 & -0.1396 \\ 0 & -0.2673 & -0.1396 & 0.9535 \end{pmatrix}$$

所以

$$H_1 A_1 H_1 = \begin{pmatrix} 6 & -3.7417 & 0 & 0 \\ -3.7417 & 13.8756 & 1.8079 & -3.1394 \\ 0 & 1.8079 & 4.2912 & -6.0079 \\ 0 & -3.1394 & -6.0079 & 2.8512 \end{pmatrix} = A_2$$



记

$$b_2 = \begin{pmatrix} -3.7417 \\ 13.8756 \\ 1.8079 \\ -3.1394 \end{pmatrix}$$

取

$$u_2 = \begin{pmatrix} -3.7417 \\ 13.8756 \\ -\sqrt{1.8079^2 + (-3.1394)^2} \\ 0 \end{pmatrix} = \begin{pmatrix} -3.7417 \\ 13.8756 \\ -3.6228 \\ 0 \end{pmatrix}$$

则

$$v_2 = b_2 - u_2 = \begin{pmatrix} 0 \\ 0 \\ 5.4307 \\ -3.1394 \end{pmatrix}, \quad \|v_2\|_2^2 = 39.3483.$$



从而

$$H_2 = I - \frac{2v_2 v_2^T}{\|v_2\|_2^2} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & -0.499 & 0.866 \\ 0 & 0 & 0.866 & 0.499 \end{pmatrix}$$

所以

$$H_2 A_2 H_2 = \begin{pmatrix} 6 & -3.7417 & 0 & 0 \\ -3.7417 & 13.8576 & -3.6227 & 0 \\ 0 & -3.6227 & 8.4058 & -3.6387 \\ 0 & 0 & -3.6387 & -1.2634 \end{pmatrix} = A_3$$

显然,  $A_3$  为所求对称三对角阵.



**定义：** 对于方阵 $A$ ，如果当 $i > j+1$ 时，有 $a_{ij} = 0$ ，则称 $A$ 为上  
海森伯格矩阵，即

$$A = \begin{bmatrix} a_{11} & a_{11} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ & \ddots & \ddots & \vdots \\ & & a_{nn-1} & a_{nn} \end{bmatrix}$$



## § 4 QR 方法

定理:  $A \in \mathbf{R}^{n \times n}$  可逆, 则存在正交阵  $Q$  使

$$Q^T A Q = \begin{pmatrix} R_{11} & R_{12} & \cdots & R_{1m} \\ & R_{22} & \cdots & R_{2m} \\ & & \cdots & \cdots \\ & & & R_{mm} \end{pmatrix}$$

$R_{ii}$  至多2阶. 若1阶, 其元素即  $A$  的特征值; 若2阶其特征值为  $A$  的一对共轭复特征值.



定理：设  $A \in R^{n \times n}$ ，则  $A$  正交相似于一个  $n$  阶上海森伯格矩阵

$$\begin{pmatrix} * & * & * & \dots & * \\ * & * & * & \dots & * \\ 0 & * & * & \dots & * \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & * & * \end{pmatrix} \quad (i > j + 1 \Rightarrow a_{ij} = 0).$$

## QR方法的基本公式

设  $A_1 = Q_1 R_1$ （ $QR$ 分解），令  $A_2 = R_1 Q_1$ ，再次将矩阵  $A_2$  作  $QR$  分解，不妨设  $A_2 = Q_2 R_2$ ，令  $A_3 = R_2 Q_2$ ，一般地，有



$$\begin{cases} A_k = Q_k R_k, & (QR \text{分解}) \\ A_{k+1} = R_k Q_k. & (\text{迭代定义}) \end{cases} \quad k = 1, 2, \dots$$

## QR基本算法:

1. 对  $A^{(k)}$  作  $QR$  分解  $A^{(k)} = Q_k R_k$ .
2. 逆序相乘  $A^{(k)}$  的分解矩阵,  $A^{(k)} = R_k Q_k$ .
3. 判别  $A^{(k+1)}$  是否为主对角线为  $1 \times 1$  或  $2 \times 2$  的子块形式的分块上三角形矩阵, 若是对角线上各子块的特征值为所求特征值, 终止, 否则  $k+1 \rightarrow k$ , 转1.



例：用 $QR$ 方法求的 $A$ 特征值，其中  $A = \begin{pmatrix} 5 & -2 & -5 & -1 \\ 1 & 0 & -3 & 2 \\ 0 & 2 & 2 & -3 \\ 0 & 0 & 1 & -2 \end{pmatrix}$

解：记 $A^{(0)}=A$ ，采用正交变换将 $A^{(0)}$ 做 $QR$ 分解，得 $A^{(0)}=Q_0R_0$ ，其中

$$Q_0 = \begin{pmatrix} 0.9806 & -0.0377 & 0.1923 & -0.1038 \\ 0.1961 & 0.1887 & -0.8804 & -1.4192 \\ 0 & 0.9813 & 0.1761 & 0.0740 \\ 0 & 0 & 0.3962 & -0.8998 \end{pmatrix} \quad R_0 = \begin{pmatrix} 5.0992 & -1.9612 & -5.4912 & -0.3922 \\ 0 & 2.0381 & 1.5852 & -2.5288 \\ 0 & 0 & 2.5242 & -3.2736 \\ 0 & 0 & 0 & 0.7822 \end{pmatrix}$$

做逆序相乘





$$A^{(1)} = R_0 Q_0 = \begin{pmatrix} 4.6157 & 5.9508 & 1.5992 & 0.2390 \\ 0.3997 & 1.9401 & -2.5717 & 1.5361 \\ 0 & 2.4770 & -0.8525 & 3.1294 \\ 0 & 0 & 0.3099 & -0.7031 \end{pmatrix}$$

继续做下去，经过11次计算后，有

$$A^{(11)} = \begin{pmatrix} 4.0000 & * & * & * \\ 0 & 1.8789 & -3.5910 & * \\ 0 & 1.3290 & 0.1211 & * \\ 0 & 0 & 0 & -1.0000 \end{pmatrix}$$

于是 $A$ 有两个实特征值为  $\lambda_1 = 4.0000$  ,  $\lambda_2 = -1.0000$  及一对共轭复特征根  $\lambda_{3,4} = 1 \pm 2i$  , 它来自  $2 \times 2$  矩阵块  $\begin{pmatrix} 1.8789 & -3.5910 \\ 1.3290 & 0.1211 \end{pmatrix}$  的特征根.



## 改进的QR方法

(1) 对于一般的矩阵在使用 $QR$ 方法之前, 可先 $A$ 将作正交相似变换化为上海森伯格矩阵 $H$ , 然后对 $H$ 作 $QR$ 迭代, 可大量节省运算量.

(2) 对上海森伯格矩阵用吉文斯变换作 $QR$ 分解

$$R(i, i+1, \theta_i)H = \begin{bmatrix} 1 & & & & & & \\ & \ddots & & & & & \\ & & 1 & & & & \\ & & & c_i & s_i & & \\ & & & -s_i & c_i & & \\ & & & & & 1 & \\ & & & & & & \ddots \\ & & & & & & & 1 \end{bmatrix} \begin{bmatrix} h_{11} & h_{12} & \cdots & h_{1i} & \cdots & h_{1,n-1} & h_{1n} \\ h_{21} & h_{22} & \cdots & h_{2i} & \cdots & h_{2,n-1} & h_{2n} \\ & \ddots & \ddots & \cdots & \cdots & \vdots & \vdots \\ & & & h_{ii} & \cdots & h_{i,n-1} & h_{i,n} \\ & & & h_{i+1,i} & \cdots & h_{i+1,n-1} & h_{i+1,n} \\ & & & & \ddots & \vdots & \vdots \\ & & & & & h_{n,n-1} & h_{n,n} \end{bmatrix}$$



(3) 记 $H_1 = H$ , 设 $H_1 = U_1 R_1$  令 $H_2 = R_1 U_1$ . 由于 $R_1$ 为上三角,  
 $U_1$ 为上海森伯格阵, 所以 $H_2$ 为上海森伯格阵. 此变换约需 $4n^2$ 次  
乘除和加减运算.

